

Conclusão

O objetivo deste projeto foi desenvolver modelos de classificação utilizando SVM para prever a probabilidade de compra de um produto com base nas variáveis Gender, Age e AnnualSalary. Foram testados diferentes kernels (linear, polinomial e RBF), além da utilização de GridSearchCV e validação cruzada para otimização e avaliação dos modelos.

A análise exploratória mostrou que clientes com maior idade e maior renda anual possuem maior probabilidade de realizar compras. A variável Gender apresentou baixa influência no comportamento de compra.

Os modelos baseline utilizando kernel linear apresentaram resultados satisfatórios, indicando que existe uma separação relativamente boa entre as classes. O kernel polinomial apresentou melhora em alguns cenários, porém com menor estabilidade e pior recall em determinadas combinações de features. Já o kernel RBF apresentou o melhor desempenho geral, mostrando maior capacidade de capturar relações não lineares entre as variáveis.

O melhor resultado foi obtido pelo modelo:

SVM GridSearch - Cross Validation - Top Features

utilizando apenas as variáveis:

Age

AnnualSalary

O modelo final apresentou aproximadamente:

- Accuracy: 0.91
- Precision: 0.87
- Recall: 0.91
- F1-score: 0.89
- ROC AUC: 0.95

A análise de importância das variáveis mostrou que Age foi a feature mais relevante, seguida por AnnualSalary, enquanto Gender teve pouca contribuição para o modelo. Isso permitiu reduzir o número de variáveis sem perda de desempenho.

Comparando com o projeto anterior utilizando XGBoost, os resultados ficaram muito próximos. O XGBoost apresentou leve vantagem em alguns cenários, porém o SVM com kernel RBF conseguiu desempenho semelhante mesmo utilizando uma abordagem diferente de modelagem. Isso demonstra que o problema possui

boa separação entre as classes e pode ser resolvido de forma eficiente por diferentes algoritmos de machine learning.

De forma geral, o projeto mostrou que modelos SVM, principalmente com kernel RBF, possuem excelente desempenho para problemas de classificação binária envolvendo poucas variáveis numéricas e relações não lineares.