

Conclusão

Neste projeto foi desenvolvido um pipeline completo de Machine Learning utilizando o dataset do Titanic Kaggle Competition, com o objetivo de prever a sobrevivência dos passageiros do Titanic.

Inicialmente, foi realizada a etapa de análise exploratória dos dados (EDA), permitindo identificar padrões importantes relacionados à sobrevivência. Durante essa análise, observou-se que variáveis como sexo, classe social, presença de cabine e tamanho da família apresentavam forte relação com o target (Survived).

Para melhorar a qualidade do modelo, foi aplicado um processo de feature engineering. Novas variáveis foram criadas, como:

- HasCabin: identifica passageiros que possuíam cabine registrada;
- FamilySize: quantidade de familiares viajando juntos;
- FarePerPerson: tarifa dividida pelo tamanho da família;
- Title: título extraído do nome do passageiro (Mr, Mrs, Miss, Master, etc.);
- AgeGroup: categorização da idade em faixas.

Essas transformações ajudaram o modelo a capturar informações sociais e comportamentais que não estavam explícitas nas variáveis originais. A variável Title, por exemplo, trouxe um ganho importante por representar simultaneamente fatores como sexo, idade e posição social do passageiro.

Também foi implementado um pipeline completo de pré-processamento utilizando:

- imputação de valores nulos;
- padronização numérica (StandardScaler);
- codificação de variáveis categóricas (OneHotEncoder).

A utilização de pipelines garantiu que todo o processamento fosse executado corretamente tanto durante o treinamento quanto durante a validação cruzada e geração das previsões finais.

Foram avaliados três algoritmos principais:

- XGBoost
- Support Vector Machine
- Logistic Regression

Cada modelo foi testado em:

- versão baseline;
- versão otimizada com GridSearchCV;
- validação cruzada estratificada (StratifiedKFold).

Os resultados mostraram que todos os modelos apresentaram desempenho competitivo, indicando que o pré-processamento e o feature engineering tiveram impacto positivo na generalização do modelo.

Por fim, foi implementado um ensemble utilizando Soft Voting, combinando os três algoritmos. Essa abordagem permitiu unir as vantagens individuais de cada modelo:

- o XGBoost capturando relações complexas e não lineares;
- o SVM realizando separações geométricas eficientes;
- a Regressão Logística fornecendo previsões mais estáveis e probabilidades bem calibradas.

O ensemble apresentou o melhor desempenho geral durante a validação cruzada, atingindo aproximadamente:

- Accuracy: 0.836
- F1-score: 0.775
- ROC AUC: 0.878

Esses resultados demonstram que a combinação de modelos distintos contribuiu para reduzir erros individuais e melhorar a capacidade de generalização.

Ao final do projeto, também foi gerado automaticamente o arquivo `submission.csv`, contendo as previsões finais para a plataforma Kaggle. O pipeline desenvolvido ficou modular, reutilizável e próximo de um fluxo utilizado em projetos reais de Data Science e Machine Learning.