

Apontamento de Boas Práticas

1. Definição clara da tarefa

O problema foi definido de forma objetiva: classificar manchetes de notícias em categorias específicas. Essa clareza ajuda o modelo a entender exatamente qual saída é esperada.

2. Uso de dados estruturados e rotulados

Foi utilizada uma base com textos e classes conhecidas, permitindo treinar, validar e comparar os modelos de forma supervisionada.

3. Pré-processamento textual

Foram removidos elementos de HTML, símbolos e ruídos textuais antes da aplicação do TF-IDF. Isso melhora a qualidade das features geradas e reduz interferências desnecessárias.

4. Comparação entre modelos

Foram testados Logistic Regression e SVM, com baseline, GridSearch e Cross Validation. Isso evita depender de um único modelo e permite escolher a abordagem com melhor desempenho.

5. Uso de validação cruzada

A validação cruzada foi utilizada para avaliar a estabilidade dos modelos em diferentes divisões da base, reduzindo a dependência de um único train/test split.

Reflexão Ética

O uso de modelos de PLN para classificação automática de notícias deve respeitar princípios de transparência, responsabilidade e proteção de dados. É importante informar que a classificação foi realizada por um modelo estatístico, sujeito a erros, e que os resultados não devem ser tratados como verdade absoluta sem validação humana, principalmente em contextos sensíveis.

Também é necessário evitar preconceitos na categorização das notícias. Como o modelo aprende padrões a partir dos dados de treinamento, ele pode reproduzir vieses existentes na base, como maior associação de certos termos, países ou grupos sociais a determinadas categorias. Por isso, é recomendável avaliar erros por classe, acompanhar métricas macro e revisar exemplos classificados incorretamente.

Além disso, mesmo que notícias sejam geralmente públicas, elas podem conter nomes, locais, opiniões ou informações pessoais. Portanto, o uso do modelo deve respeitar a LGPD, evitando exposição desnecessária de dados pessoais, armazenando apenas informações necessárias e garantindo finalidade clara para o tratamento dos dados. Em aplicações reais, seria importante anonimizar

informações sensíveis sempre que possível e manter controle sobre o acesso aos dados e aos resultados gerados pelo modelo.